

初始化在优化过程中起着重要的作用,随机或全零初始化在传统的优化方案中被广泛使用,如 ADMM。为了保留细节,同时避免引起失真,作者提出了一个数据依赖的初始化模块 D,该模块使用全卷积(Conv)网络自适应地同时学习 R_0 和 L_0 。初始化模块由三个 Conv+LeakyReLU 层组成,然后是卷积层和 ReLU 层。整个卷积层的核大小设置为 3×3 。对于初始化低光图像的两个分量,损失函数设计如下:

$$\min ||I - R_0 \cdot L_0||_1 + \mu ||L_0 - \max I^{(c)}||_F^2 \quad (7)$$

在展开优化模块中,以正光图像的反射率为参考。在初始化模块网络架构的基础上,进一步实现了结构感知平滑。对正光图像的照度约束,则分解正光图像的损失函数为:

$$\min ||I - R \cdot L||_1 + \mu ||L - \max I^{(c)}||_F^2 + ||e^{-\epsilon \nabla I} \cdot \nabla L||_1 \quad (8)$$

2.3 展开优化模块

展开优化模块旨在迭代求解四个单变量子问题,在 T 次迭代中更新相应的变量。通过将更新步骤映射到深度神经网络架构,推理被展开为 T 个阶段,每个阶段对应于一个迭代,其中 P, Q, L 和 R 以替代方式更新。

更新 P 和 Q 的规则: P 子问题是一个经典的最小二乘问题,通过对 Eq.(3)对 P 求导并令其导数为 0,可以得到其闭式解,因此,给定初始化的反射率和 P -子问题的闭型解,关于 P 的更新公式为:

$$P_k = F_P(I, R_{k-1}, Q_{k-1}, \gamma) = \begin{cases} R_0, & k = 1 \\ \frac{\gamma R_{k-1} + I \cdot Q_{k-1}}{Q_{k-1} \cdot Q_{k-1} + \gamma 1} \end{cases} \quad (9)$$

Q 的更新可以通过求解式(7)中的 q 子问题来实现。在 RGB 空间中恢复低光图像时,三个通道的反射率层共用同一照明层,因此假设照明为灰度。因此,将式(5)改写为

$$Q_k = \sum_{c \in \{R, G, B\}} \min ||I - P_k \cdot Q||_F^2 + \lambda ||Q - L_{k-1}||_F^2 \quad (10)$$

它的闭型解很容易找到。考虑初始化光照,得到 Q 的更新公式为:

$$Q_k = F_Q(I, L_{k-1}, P_k, \lambda) = \begin{cases} R_0, & k = 1 \\ \frac{\gamma L_{k-1} + \sum_{c \in \{R, G, B\}} I^{(c)} \cdot P_k^{(c)}}{\sum_{c \in \{R, G, B\}} P_k^{(c)} \cdot P_k^{(c)} + \lambda 1} \end{cases} \quad (11)$$

L 和 R 的更新规则:作者开发了基于学习的方法来探索来自现实世界数据的隐式先验,而不是引入手工制作的先验来手动设计特定的损失函数。即引入 GL 和 GR 两个网络分别对 L 和 R 进行更新,具体来说,用于拟合 L 上物理先验的网络表示为:

$$L_k = G_L(Q_K; \theta_L) \quad (12)$$

采用一个简单的全卷积网络,包含 5 个 Conv 层,然后通过 ReLU 激活来学习 L 上的隐式先验,从而可以从训练数据中学习先验,同时避免了设计复杂的正则化项:

$$R_k = G_R(P_k, Q_K; \theta_R) \quad (13)$$

展开优化模块采用端到端方式进行训练，在不同阶段共享 G_R 和 G_L 的参数和网络架构。在展开网络的优化过程中，我们的初始化模块生成的光反射率 R 作为参考。对于损失函数，我们采用反射率和照度损失函数之和，其中包括各阶段 P_k 和 R_k 之间的均方误差 MSE 损失、 MSE 损失、结构相似性损失、 R 与最终恢复的反射率 R_T 之间的感知损失、 Q_k 和 L_k 之间的 MSE 损失以及 L_k 在各阶段的总变异损失。展开优化模块的损失函数为：

$$\min \sum_{k=1}^T (\gamma_k ||P_k - R_k||_F^2 + \lambda_k ||Q_k - L_k||_F^2) + \beta ||\nabla L_T||_1 + \alpha (||\phi(R) - \phi(R_T)||_1 + ||R - R_T||_F^2 + (1 - SSIM(R, R_T))) \quad (14)$$

这样即使在深度神经网络架构中，所提出的展开优化模块具有很好的可解释性，其中 F_P 、 F_Q 、 G_L 、 G_R 都有明确的含义。而且，它避免了显式的正则化设计，并以深度学习的方式自适应恢复光照和反射率。

2.4 照明调节模块

在实际中，没有用于图像增强的真地亮度，需要灵活调整照度以适应不同的实际要求。我们提出了一个照度调节模块，该模块取低照度 L 和用户特定的增强比 ω 作为输入，表示为：

$$L = A(L, \omega, \theta_A)$$

由于光照贴图的分布不均匀，展开 ω 到一个与 L 相同大小的贴图，这样，通过传递的串联得到调整后的照度 L 。考虑到计算效率，采用与初始化模块相同的轻量级网络结构。为了保持一致性和平滑地调整光照，该模块中的卷积核尺寸被放大到 5×5 。

照度调节模块的损失函数为：

$$\min ||\nabla I - \nabla L||_1 + ||R \cdot L - I||_F^2 + (1 - SSIM(R, L, I)) \quad (15)$$

3 本文方法

3.1 本文方法概述

本文是对基于 Retinex 的深度展开网络的低光图像增强这篇论文的复现，因此介绍一下这篇论文提出的模型的内容。

3.2 模型

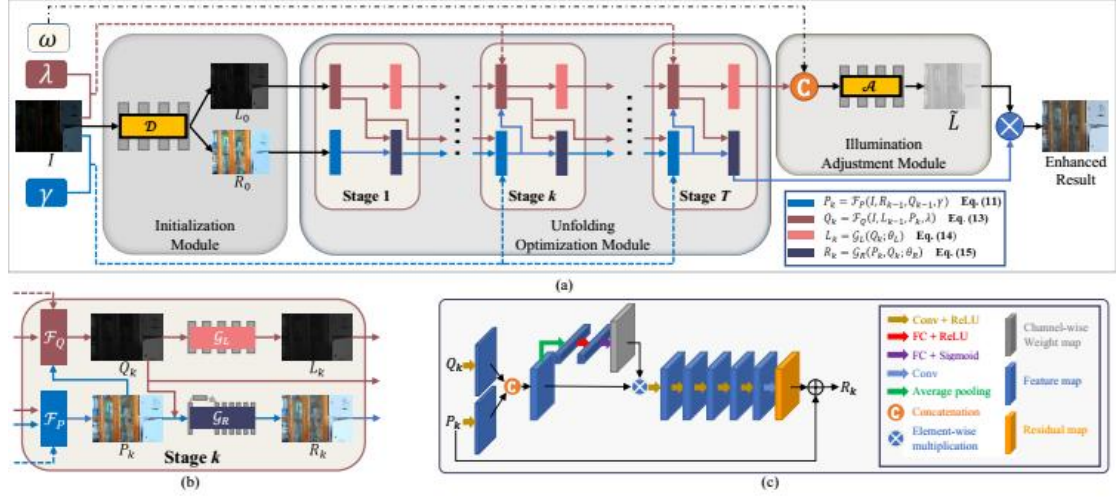


图 1: URetinex-Net 示意图

URetinex-Net 网络结构如图一所示，其模型结构相对简单，主要由初始化模块，展开优化模块，照明调整模块组成。初始化模块通过卷积网络生成初始的 $L_0 I_0$ ；优化展开模块旨在迭代求解四个单变量子问题，在 T 次迭代中更新相应的变量。通过将更新步骤映射到深度神经网络架构，推理被展开为 T 个阶段，每个阶段对应于一个迭代，其中 P, Q, L 和 R 以替代方式更新；光照调整模块根据用户设定的比例输出增强后的正光版本。

4 复现细节

4.1 与已有开源代码对比

原文的主要亮点是通过提出 URetinex-Net 网络将一个优化问题展开为一个可学习的网络，以将低光图像分解为反射层和光照层。通过将分解问题公式化为隐式先验正则化模型，精心设计了三个基于学习的模块，分别负责数据相关的初始化、高效的展开优化和用户指定的光照增强。特别地，所提出的展开优化模块通过引入两个网络，以数据驱动的方式自适应拟合隐式先验，实现了最终分解结果的噪声抑制和细节保留。作者提供的源码只有训练好的模型，而预训练的源码并未在提供的代码中给出。开始尝试自己手写预训练的代码，但发现自己写的代码始终不能跑起来，于是尝试复现作者提供的训练好的模型的结果，并尝试微调一些参数看结果是否有改进。

4.2 实验环境搭建

采用的是 Pytorch 的模型框架，主要的实验环境如下：

Python == 3.7.6, PyTorch == 1.4.0, Torchvision == 0.5.0

4.3 创新点


本次实验的创新点创新点相对较少，主要是对现有工作的复现。原论文只在 LOL,SICE 两个配对数据集上测试了结果，在未配对数据集 MEF 使用该方法进行进一步检验泛化性能。同时使用了新的图像质量评估指标 NUI,BRI 来作为评估指标。

5 实验结果分析

在 LOL 数据集上的结果：



在 SICE 数据集上的结果：



在这两个数据集使用以下四个指标进行评估：

MAE(Mean Absolute Error)

PSNR(Peak Signal-to-noise Ratio)

SSIM(Structural Similarity Index)

LPIPS(Perceptual Image Patch Similarity)

在 MAE 数据集上的结果：

(a)Input



(b)URet-
inex



MAE: 0.0811 PSNR: 22.2654 SSIM: 0.8154 LPIPS: 1.3265

(c)Re-
tinex



MAE: 0.1256 PSNR: 16.8456 SSIM: 0.5614 LPIPS: 2.5645

作为对比，同时测试了基于 Retinex 的传统方法的效果来和 URetinex 比较，在为配对数据集 MAE 上，URetinex 在四项指标仍要好于传统 Retinex。

用自己拍摄的照片测试：



对于普通低光图像 URetinex 取得了较好的效果，但对于同时存在曝光强和曝光弱的图片会出现过曝光的情况，并且对于图像的语义信息也没有很好的处理。

6 总结与展望

本次实验的不足之处主要在复现的模型相对简单，且缺少创新性的改进。对于没有完全开源的模型，由于能力有限没有自己把预训练部分复现出来，只是测试了一遍已经训练好的结果并且尝试加入更多的评价指标和未配对数据集来检测该模型的效果。同时从测试结果来看，离论文结果尚有一定差距，这主要是模型未调参以及对模型细节不清晰导致的。但是基于 Retinex 方法的低光增强方法具有巨大的进步空间，近期还有一篇文章提出了一种对比学习方法和一种自我知识蒸馏方法，允许在没有额外先验或正则化器的情况下训练基于 Retinex 的模型，未来可以找出更多此类方法。

参考文献

[1] Stephen Boyd, Neal Parikh, and Eric Chu. Distributed optimization and statistical learning via the alternating direction method of multipliers. Now Publishers Inc, 2011. 4

- [2] Jianrui Cai, Shuhang Gu, and Lei Zhang. Learning a deep single image contrast enhancer from multi-exposure images. *IEEE Transactions on Image Processing*, 27(4):2049–2062, 2018. 6
- [3] Chen Chen, Qifeng Chen, Jia Xu, and Vladlen Koltun. Learning to see in the dark. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 3291–3300, 2018. 2
- [4] Yunjin Chen and Thomas Pock. Trainable nonlinear reaction diffusion: A flexible framework for fast and effective image restoration. *IEEE transactions on pattern analysis and machine intelligence*, 39(6):1256–1272, 2016. 3
- [5] Chunyang Cheng, Xiao-Jun Wu, Tianyang Xu, and Guoyang Chen. Unifusion: A lightweight unified image fusion network. *IEEE Transactions on Instrumentation and Measurement*, 70:1–14, 2021. 1
- [6] Kostadin Dabov, Alessandro Foi, Vladimir Katkovnik, and Karen Egiazarian. Image denoising with block-matching and 3d filtering. In *Image Processing: Algorithms and Systems, Neural Networks, and Machine Learning*, volume 6064, page 606414. International Society for Optics and Photonics, 2006. 2
- [7] Guang Deng. A generalized unsharp masking algorithm. *IEEE transactions on Image Processing*, 20(5):1249–1261, 2010. 1
- [8] Ying Ding, Xinwei Xue, Zizhong Wang, Zhiying Jiang, Xin Fan, and Zhongxuan Luo. Domain knowledge driven deep unrolling for rain removal from single image. In *2018 7th International Conference on Digital Home (ICDH)*, pages 14–19. IEEE, 2018. 3
- [9] Xueyang Fu, Delu Zeng, Yue Huang, Xiao-Ping Zhang, and Xinghao Ding. A weighted variational model for simultaneous reflectance and illumination estimation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2782–2790, 2016. 2, 6, 7
- [10] Karol Gregor and Yann LeCun. Learning fast approximations of sparse coding. In *Proceedings of the 27th international conference on international conference on machine learning*, pages 399–406, 2010. 3
- [11] Chunle Guo, Chongyi Li, Jichang Guo, Chen Change Loy, Junhui Hou, Sam Kwong, and Runmin Cong. Zero-reference deep curve estimation for low-light image enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1780–1789, 2020. 1, 2, 6, 7
- [12] Xiaojie Guo, Yu Li, and Haibin Ling. Lime: Low-light image enhancement via

illumination map estimation. IEEE Transactions on image processing, 26(2):982–993, 2016. 1,2, 4, 6, 7

[13] Shijie Hao, Xu Han, Yanrong Guo, Xin Xu, and Meng Wang. Low-light image enhancement with semi-decoupled decomposition. IEEE transactions on multimedia, 22(12):3025–3038, 2020. 2

[14] Jie Hu, Li Shen, and Gang Sun. Squeeze-and-excitation networks. In Proceedings of the IEEE conference on computer vision and pattern recognition, pages 7132–7141, 2018. 5

[15] Yifan Jiang, Xinyu Gong, Ding Liu, Yu Cheng, Chen Fang, Xiaohui Shen, Jianchao Yang, Pan Zhou, and Zhangyang Wang. Enlightengan: Deep light enhancement without paired supervision. IEEE Transactions on Image Processing, 30:2340–2349, 2021. 2

[16] Daniel J Jobson, Zia-ur Rahman, and Glenn A Woodell. A multiscale retinex for bridging the gap between color images and the human observation of scenes. IEEE Transactions on Image processing, 6(7):965–976, 1997. 1

[17] Daniel J Jobson, Zia-ur Rahman, and Glenn A Woodell. Properties and performance of a center/surround retinex. IEEE transactions on image processing, 6(3):451– 462, 1997. 1

[18] Ron Kimmel, Michael Elad, Doron Shaked, Renato Keshet, and Irwin Sobel. A variational framework for retinex. International Journal of computer vision, 52(1):7–23, 2003. 2

[19] Chulwoo Lee, Chul Lee, Young-Yoon Lee, and Chang-Su Kim. Power-constrained contrast enhancement for emissive displays based on histogram equalization. IEEE Transactions on Image Processing, 21(1):80–93, 2012. 6

[20] Chongyi Li, Chunle Guo, Ling-Hao Han, Jun Jiang, MingMing Cheng, Jinwei Gu, and Chen Change Loy. Low-light image and video enhancement using deep learning: a survey. IEEE Transactions on Pattern Analysis & Machine Intelligence, (01):1–1, 2021. 2

[21] Chengxi Li, Xiangyu Qu, Abhiram Gnanasambandam, Omar A. Elgendy, Jiaju Ma, and Stanley H. Chan. Photonlimited object detection using non-local feature matching and knowledge distillation. In Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops, pages 3976–3987, October 2021. 1

[22] Mading Li, Jiaying Liu, Wenhan Yang, Xiaoyan Sun, and Zongming Guo.

Structure-revealing low-light image enhancement via robust retinex model. *IEEE Transactions on Image Processing*, 27(6):2828–2841, 2018. 2, 3, 6, 7

[23] Jiaying Liu, Dejia Xu, Wenhao Yang, Minhao Fan, and Haofeng Huang. Benchmarking low-light image enhancement and beyond. *International Journal of Computer Vision*, 129(4):1153–1184, 2021. 1

[24] Risheng Liu, Long Ma, Jiaao Zhang, Xin Fan, and Zhongxuan Luo. Retinex-inspired unrolling with cooperative prior architecture search for low-light image enhancement. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 10561–10570, 2021. 3, 6, 7

[25] Kin Gwn Lore, Adedotun Akintayo, and Soumik Sarkar. Llnet: A deep autoencoder approach to natural low-light image enhancement. *Pattern Recognition*, 61:650–662, 2017. 2

[26] Feifan Lv, Yu Li, and Feng Lu. Attention guided lowlight image enhancement with a large scale low-light simulation dataset. *International Journal of Computer Vision*, 129(7):2175–2193, 2021. 6, 7

[27] Michael K Ng and Wei Wang. A total variation model for retinex. *SIAM Journal on Imaging Sciences*, 4(1):345–365, 2011. 1, 2